

2026 第二届大学生人工智能安全竞赛 作品报告

作品名称: CiteVerifier:基于多源学术文献库与大模型的“虚假引用”智能核验系统

作品类型: 开放式自由命题

电子邮箱: wbh-191915@qq.com

提交日期: 2026.8.2

填写说明

1. 所有参赛项目必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛项目（或方案）。
2. 作品报告采用A4纸撰写。除标题外，所有内容必需为宋体、小四号字、1.5倍行距。
3. 作品报告中各项目说明文字部分仅供参考，作品报告书撰写完毕后，请删除所有说明文字。（本页不删除）
4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。
5. 为保证网评的公平、公正，作品报告中应避免出现作者所在学校、院系和指导教师等泄露身份的信息。

目 录

摘要	1
Abstract	2
第一章 作品概述	4
1.1 背景分析	4
1.2 相关工作	6
1.3 系统设计目标	7
1.4 作品特色与应用前景	8
第二章 作品设计与实现	10
2.1 系统框架设计	10
2.2 核心模块设计	11
2.2.1 数据解析模块	11
2.2.2 文献检索模块	13
2.2.3 用户交互模块	14
2.3 系统功能	15
2.3.1 首页与快速检测入口	15
2.3.2 用户认证与访问管理	17
2.3.3 文献检索与检测结果展示	18
2.3.4 历史记录管理	21
2.3.5 多语言及中英文文献适配	22
2.3.6 平台扩展服务	23
第三章 作品测试与分析	25
3.1 功能性测试	25
3.2.1 测试目标	25
3.2.2 测试环境搭建	25
3.2.3 测试结果与分析	26
3.2 有效性测试	27
3.2.1 测试目标	27
3.2.2 测试数据集	27
3.2.3 测试结果与分析	28
3.3 作品学术成果	29
第四章 创新性说明	32
第五章 总结	34
参考文献	35

摘要

随着 ChatGPT、DeepSeek 等大语言模型在学术写作中的广泛应用，AI 幻觉引用问题逐渐受到关注。该现象是指模型生成格式规范、内容看似可信但实际并不存在的虚假文献。此类引用具有较强迷惑性，难以通过肉眼判断或传统查重工具发现，一旦进入论文、课程报告或科研材料，可能削弱学术文本可信度，并沿引用链条持续传播，影响知识追溯、学术评价和生成式人工智能安全治理。因此，面向 AI 幻觉引用的自动化核验已成为学术内容可信保障的重要需求。

针对上述问题，本作品设计并实现了 **CiteVerifier：基于多源学术文献库与大模型的“虚假引用”智能核验系统**。系统以参考文献标题为主要核验依据，构建了从参考文献解析、多源检索、相似度匹配到结果反馈的自动化流程。平台不要求用户必须提供 DOI、URL 等唯一标识符，而是结合本地 DBLP 英文文献知识库、中文学术检索源和大语言模型解析能力，支持从 PDF 文档、CSV 文件和批量文本中提取待核验文献信息，降低人工整理和逐条检索成本。

本作品的主要贡献包括：一是从模型生成引用和真实论文引用两个角度开展实验分析，验证虚假引用问题的存在性；二是提出多源学术数据支撑的标题级引用核验方法，通过候选召回与相似度匹配完成真实性判断，适应无 DOI、格式不规范和中英文混合引用场景；三是实现面向非结构化参考文献的智能解析能力，能够处理 PDF 编号不统一、换行混乱和多语言混排等情况；四是构建面向学术写作和论文审查的核验平台，支持单条检测、批量检测、进度展示、历史记录和结果导出。

实验结果表明，13 款主流大语言模型生成参考文献的幻觉率分布于 14.23% ~ 94.93%；对 2020—2025 年 56,381 篇国际顶级会议论文、超过 220 万条参考文献的检测也显示，真实论文中已出现无效引用和来源不可追溯引用。有效性测试验证了以 0.9 作为相似度判定阈值的合理性；功能性测试中，平台 69 项测试用例全部通过。总体来看，CiteVerifier 形成了“实验验证—数据支撑—平台核验—结果复核”的完整技术路线，可应用于论文写作、毕业论文审核、期刊会议初审、科研诚信管理和 AI 生成内容治理等场景，为降低虚假引用进入正式学术文本的风险提供工程化解决方案。

关键词：学术引用核验；AI 幻觉引用；大语言模型；人工智能安全

Abstract

With the widespread use of large language models such as ChatGPT and DeepSeek in academic writing, the issue of AI hallucinated citations has attracted increasing attention. This phenomenon refers to fabricated references generated by models that appear standardized in format and credible in content but do not actually exist. Such citations are highly misleading and difficult to identify through manual judgment or traditional plagiarism detection tools. Once introduced into papers, course reports, or research materials, they may weaken the credibility of academic texts and continue to spread along citation chains, affecting knowledge tracing, academic evaluation, and the governance of generative AI safety. Therefore, automated verification of AI hallucinated citations has become an important requirement for ensuring the credibility of academic content.

To address this problem, this work designs and implements CiteVerifier, an intelligent verification system for “fabricated citations” based on multi-source academic literature databases and large language models. Taking reference titles as the primary verification basis, the system builds an automated workflow covering reference parsing, multi-source retrieval, similarity matching, and result feedback. The platform does not require users to provide unique identifiers such as DOI or URL. Instead, it integrates a local DBLP English literature knowledge base, Chinese academic retrieval sources, and large language model-based parsing capabilities to extract references to be verified from PDF documents, CSV files, and batch text, thereby reducing the cost of manual organization and item-by-item retrieval.

The main contributions of this work are as follows. First, experiments are conducted from the perspectives of model-generated citations and citations in real papers to verify the existence of fabricated citation problems. Second, a title-level citation verification method supported by multi-source academic data is proposed. It determines citation authenticity through candidate retrieval and similarity matching, and adapts to scenarios involving missing DOI, irregular formats, and mixed Chinese-English references. Third, an intelligent parsing capability for unstructured references is implemented, which can handle

inconsistent PDF numbering, disordered line breaks, and multilingual mixed references. Fourth, a verification platform for academic writing and paper review is built, supporting single-item detection, batch detection, progress display, history management, and result export.

Experimental results show that the hallucinated citation rates of references generated by 13 mainstream large language models range from 14.23% to 94.93%. The analysis of 56,381 papers from top international conferences published between 2020 and 2025, involving more than 2.2 million references, also indicates that invalid citations and untraceable sources have already appeared in real papers. Effectiveness tests verify the rationality of using 0.9 as the similarity threshold. In functional testing, all 69 test cases of the platform passed. Overall, CiteVerifier forms a complete technical route of “experimental validation, data support, platform verification, and result review.” It can be applied to paper writing, undergraduate thesis review, journal and conference preliminary review, research integrity management, and AI-generated content governance, providing an engineering solution to reduce the risk of fabricated citations entering formal academic texts.

Keywords: academic citation verification; AI hallucinated citation; large language model; AI Security

第一章 作品概述

1.1 背景分析



图 1.1: AI 幻觉引用风险传导机制图

自 2022 年 11 月 OpenAI 发布 ChatGPT 以来，生成式人工智能迅速发展，并应用于学术写作等多个领域，用户借助它们可以显著提高信息处理的效率。

然而，大语言模型（Large Language Model, LLM）基于训练语料的统计规律进行概率预测的工作机制，使其可能生成与**事实**不符的内容，即模型“幻觉”。在学术场景中，AI 可能将真实存在的作者、期刊等信息进行组合，生成格式规范但现实中不存在的参考文献，这就是 **AI 幻觉引用（AI Hallucinated Citation）**¹。此类引用具备完整的文献特征，迷惑性强，传统格式检查难以识别。而参考文献作为保障知识可追溯性和学术可信度的关键，一旦被虚假引用渗透，将直接损害学术评价机制的公信力和科研诚信²。



图 1.2: 幻觉引用的典型表现

现实案例进一步说明了该问题的严重性。2023 年，美国 Mata v. Avianca 案中，两名律师引用了 ChatGPT 生成的六篇虚假判例，最终受到法院处罚³，这表明 AI 幻觉引用已经从理论风险演变为实际挑战。

随着 AI 辅助写作工具的进一步普及，人工逐条核验的方式难以满足大规模引用检测需求；同时，参考文献格式不统一、中英文混合等情况又增加了自动化处理的难度。因此，构建能够自动解析参考文献、多源检索并完成真实性判断的智能化核验系统，对于提升学术内容可信度和降低 AI 幻觉引用风险具有重要意义。

1.2 相关工作



图 1.3: AI 幻觉引用的相关研究演进示意图

随着大语言模型在学术写作领域的广泛应用，AI 幻觉问题逐渐成为当下研究关注的重点。Ji 等人系统综述了自然语言生成中的幻觉问题，指出幻觉通常表现为生成内容与事实依据之间的不一致，是生成式模型长期存在的重要可靠性问题¹。Bender 等人进一步指出，大语言模型虽然能够生成流畅文本，但在缺乏事实约束时可能产生看似合理但无法验证的信息⁴。

在引用真实性问题方面，传统引用错误主要表现为元数据错误或遗漏，而 AI 幻觉引用则是生成现实中不存在的文献。Zuccon 等人研究发现，ChatGPT 可能会生成无法追溯或无法支持其回答的引用⁵。Naser 对多种大语言模型引用生成行为的评估进一步表明不同模型均存在虚假文献生成问题⁶。

针对上述问题，现有研究主要从外部数据库检索、文献元数据匹配以及语义一致性分析等方向展开，通过比对 DBLP、Crossref 等学术数据源判断引用真实性⁷⁸。近年来，也出现了一些面向 AI 幻觉引用检测的工具，例如 Hallucinator 通过提取论文参考文献并调用多个学术数据库进行验证，从而发现潜在虚假引用⁹。

总体而言，现有研究已证实大语言模型生成虚假引用的现实风险，并探索了基于文献检索和信息匹配的自动化检测方法，但对于复杂 PDF 文档解析、中英文混合引用等实际应用场景仍存在提升空间。

1.3 系统设计目标



图 1.4：系统需求分析图



图 1.5：系统设计目标

本项目的核心目标是构建一套面向学术引用真实性核验的开源平台，以本地 DBLP 数据库、中文学术检索源与大语言模型辅助解析为支撑，结合高性能并发检索机制，为用户提供高效、准确、易用的中英文引用核验服务。

具体设计目标包括以下三个方面：

1. **多源引用与中英文高精度核验。**针对学术研究中参考文献来源多样、引用格式复杂等特点，系统支持各类引用信息的自动解析与标准化处理，并对标题词序变化和格式差异具有较好的适应能力，确保核验结果的准确性与鲁棒性。

2. **面向大规模引用的批量检测。**针对论文参考文献数量较多的问题，系统设计高效的批量处理机制，在保证准确性的前提下缩短整体处理时间，为大规模核验提供性能保障。

3. **用户交互与结果管理。**为提升易用性与实用价值，平台提供清晰便捷的用户交互方式，同时支持历史检测记录的管理与追溯，降低使用门槛，满足学术写作、论文审核等场景的实际需求。

基于以上目标，CiteVerifier 融合多源学术文献库与大语言模型解析能力，为学术写作、毕业论文等场景提供可靠、高效的引用真实性核验服务，为学术内容可信度验证与 AI 幻觉引用风险防控提供新的技术路径。

1.4 作品特色与应用前景




图 1.6: 系统特色与研究意义

本系统围绕学术论文引用真实性检测¹⁰构建，核心部分包括数据解析模块、文献

检索模块和**用户交互模块**，构建了从参考文献解析、候选文献检索到真实性判断的自动化核验流程。

在技术设计方面，数据解析模块负责对参考文献信息进行提取与结构化处理；文献检索模块结合多源学术数据完成候选文献检索，并通过标题相似度分析实现引用真实性核验¹¹；用户交互模块提供检测任务提交、结果展示及历史记录管理等功能。

在技术特点方面，系统采用多源数据支撑的引用核验方法，结合本地数据库与在线学术检索源，扩大文献覆盖范围；引入 LLM 提取文献标题，提高复杂环境下的解析能力；通过标题标准化和相似度匹配，提高引用真实性检测的准确性与鲁棒性。

从应用价值来看，系统可应用于个人学术写作、期刊论文审核以及科研诚信管理等场景，帮助用户快速核查 AI 生成或整理的参考文献，提升学术内容的可靠性。

总体而言，CiteVerifier 将人工智能安全与学术信息可信验证相结合，通过自动化引用核验机制，为生成式人工智能应用过程中的内容真实性保障提供了一种可落地的技术方案。



图 1.7：系统应用前景

第二章 作品设计与实现

2.1 系统框架设计

本系统采用前后端分离的架构，整体围绕“用户输入—数据解析—文献检索—相似度计算—结果返回”的闭环流程展开，分为数据解析模块、文献检索模块和用户交互模块。前端负责完成用户交互、任务提交、结果展示与历史记录管理；后端负责接收请求、调度各功能模块、执行引用核验并将结果返回前端。对于单条引用检测，系统先对输入标题进行规范化处理，再在本地文献库中以及百度学术搜索中分别对英文、中文文献完成候选检索与相似度匹配，最终输出匹配文献及核验结论；对于 PDF 批量检测，系统会先自动识别并提取参考文献内容，再对全部条目并发核验，并通过进度反馈机制向用户实时展示任务状态。整体设计既保证了功能流程的完整性，也提升了系统的可用性与交互体验。




图 2.1: 系统总体架构图

在数据层设计上，系统以百度学术文献库和本地 DBLP 全量文献数据为核心支撑，构建了面向非结构化引用的核验能力。考虑到实际场景中的参考文献往往存在格式差异、词序变化、特殊符号缺失以及人工录入错误，系统并不依赖 DOI 或单一在线接口，而是通过本地文献库实现快速检索与稳定匹配；当全文检索不可用时，还可借助预构建的倒排索引或全表扫描策略保证系统在不同环境下仍具备可用性。候选集生成

后，系统进一步采用模糊字符串相似度算法进行精确排序，从而在保证效率的同时提高标题匹配的准确性与鲁棒性。

从功能实现角度看，系统的工作流可以概括为“解析—检索—分析—返回”四个阶段：解析模块负责将 PDF 中的参考文献段落或用户输入的非结构化标题转换为可处理的结构化信息；检索模块优先从本地缓存和 DBLP 文献库中查找候选记录，通过相似度计算区分真实文献、元数据错误与完全捏造的虚假引用；用户交互模块则接收用户多种输入，将匹配标题、相似度得分和核验状态统一返回前端，给用户展示检索结果并支持后续保存、查询与导出。通过这一设计，CiteVerifier 实现了从原始输入到核验输出的自动化处理，为学术引用真实性核验提供了一套可部署、可扩展的工程化方案。

综上所述，本系统具有以下亮点：

- 全链路自动化：从读取用户输入、定位解析文献标题、检索、计算相似度、错误样例处理到结果输出全流程自动化。
- 高并发解析和检索：针对解析和检索流程，分别采用 `asyncio` 异步并发与 `ThreadPoolExecutor` 多线程双层并发架构，极大提高检测性能，优化用户体验。
- 多源数据结合：采用公开文献数据库 DBLP 和百度学术搜索等第三方情报源，针对中英文文献场景都有覆盖。

2.2 核心模块设计

2.2.1 数据解析模块

数据解析模块主要负责将用户输入的参考文献转换为结构化数据，它向下对接文本标题、CSV 和 PDF 三种输入源，并向上层检索服务提供标准化的文献元数据，整个模块又可以分为数据接入、文献切割和语义解析三层。

数据接入层接收用户上传的多种格式参考文献，并将其转换为系统内部统一的纯文本格式。对于 CSV 文件，系统自动识别编码和标题列并提取文献标题。对于 PDF 文档，系统使用 PyPDF2 进行文本提取以便后续处理。严格模式下通过正则表达式定位参考文献章节的起始位置；若严格模式失败则采用宽松模式进行模糊匹配，确保能

定位参考文献所在区域。提取参考文献时，系统通过 CJK 字符占比自动检测中英文，并采用不同的噪声过滤策略。英文文献主要过滤出版信息行；中文文献主要过滤页眉行及分类标题行，同时启用 OCR 修正 PyPDF2 的识别错误，并清理粘连在行首的页码数字。

文献切割层负责将 PDF 文档中提取的连续参考文献文本切分为单条记录。系统首先自动识别整体编号风格并按编号进行切割；无编号文献则采用混合切割策略，优先按空行分割，若失效则基于启发式规则逐行判断新文献起始行，以上均失败时采用按行切割的方式处理。此外，该层还支持中英文文献编号格式混排的场景，通过行首编号类型分组后分别切割再合并。

语义解析层通过调用大语言模型将单条文献字符串转换为结构化 JSON 对象。单条解析模式适用于带编号文献，每条文献独立调用 LLM，通过信号量控制实现批量并行处理；批量解析模式适用于无编号的连续文本，每 10 条文献合并为一批进行解析，显著降低 API 调用次数和响应延迟。为保证解析可靠性，该层还实现了网络层自动重试、JSON 异常时的正则字段提取、以及 LLM 解析失败时截取部分字符作为标题的容错机制。

上述的模块设计和容错机制能够适配不同格式的参考文献，为文献检索模块提供可靠的标题数据。




图 2.2: 数据解析模块示意图

2.2.2 文献检索模块

文献检索模块是系统的核心业务层，负责接收数据解析模块输出的标准化文献标题，在多个数据源中执行查询，并对结果进行综合判定与验证。

该模块首先进行数据检索，针对中英文文献采用不同的检索数据源。英文文献优先在 DBLP 本地数据库进行查询，支持 FTS5 全文检索机制和暴力匹配机制；若查询失败则在本地缓存中查询；若缓存未命中则通过谷歌学术 API 进行搜索；仍然失败就采用谷歌搜索得出最终的结果。中文文献优先在本地缓存中查询；若缓存未命中则采用爬虫技术集成百度学术进行搜索。生成候选结果后，通过相似度计算的方式对候选文献的标题和原始文献的标题进行匹配，并设定 0.9 的相似度阈值作为有效匹配的判断标准，最终结果将通过前端界面呈现给用户。

此外，由于学术论文通常包含大量的参考文献，使用串行方式处理会大大增加系统的整体耗时，因此本系统通过多线程和多浏览器并行搜索的方式显著减少了检索时间，提升系统的整体性能。

户。单标题检索的结果通过卡片的方式进行展示，批量检索的结果以列表形式展示，包含匹配状态、相似度分数等关键字段，匹配状态通过颜色标识便于用户快速浏览。用户可将当前检索结果导出为 CSV 文件进行离线分析，也可在历史记录页面查看以往的检索记录，并支持重新执行或导出历史结果。

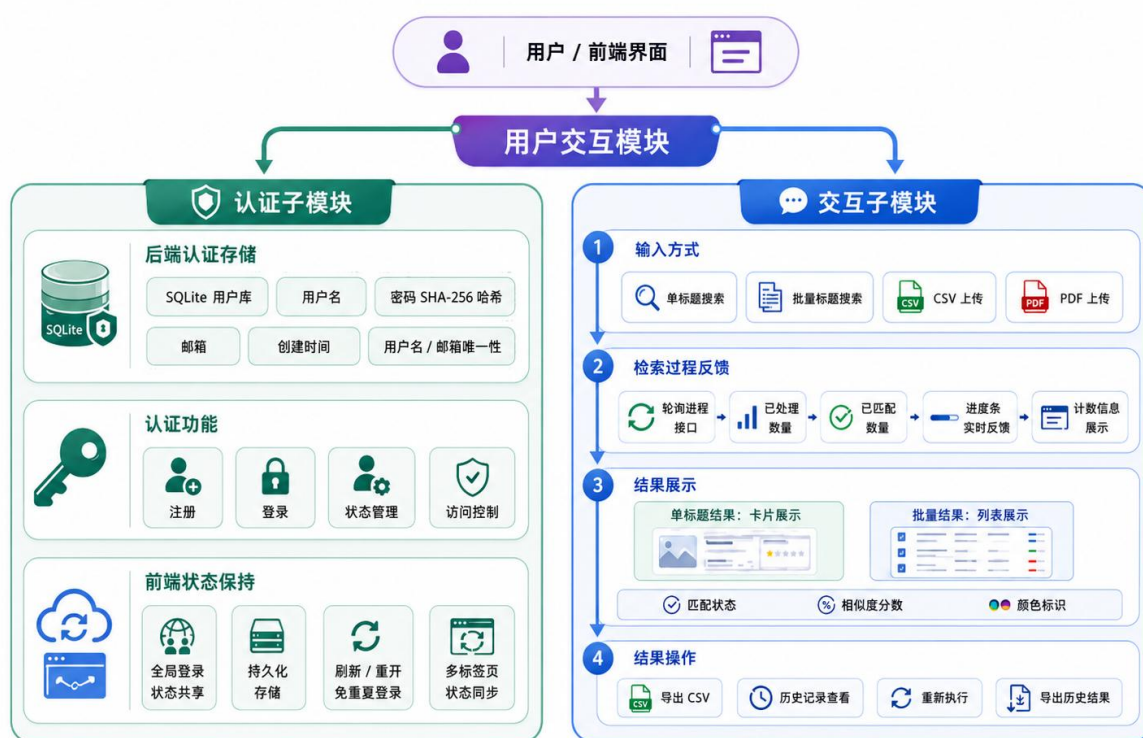


图 2.4: 用户交互模块示意图

2.3 系统功能

2.3.1 首页与快速检测入口

首页是 CiteVerifier 平台的统一入口页面，承担系统形象展示、核心能力说明和快速检测引导等功能。用户进入平台后，可以在首页首屏区域看到系统名称、核心标语和快速检测入口。页面以沉浸式背景、半透明操作面板和分区式布局突出“每一篇引用，都真实可信”的产品理念，使用户能够快速理解平台面向虚假引用核验和学术引用可信验证的定位。

首页还展示了平台的数据库比对、谷歌学术辅助检索等能力，用于说明系统并非依赖单一检索方式，而是通过多源数据与智能算法共同完成引用真实性核验。页面同时展示“极速、智能、双语”等核心优势，分别对应秒级检测、大模型辅助决策和中英文文献适配能力，帮助用户直观了解系统特点。

此外，首页下方设置的场景展示区，面向毕业论文、AI 写作、期刊投稿和文献综述等典型需求进行说明。演示视频用于展示平台操作流程、核心功能和典型检测案例，帮助新用户更直观地了解平台的使用方式。



图 2.5：系统首页




图 2.6: 系统首页 (续)

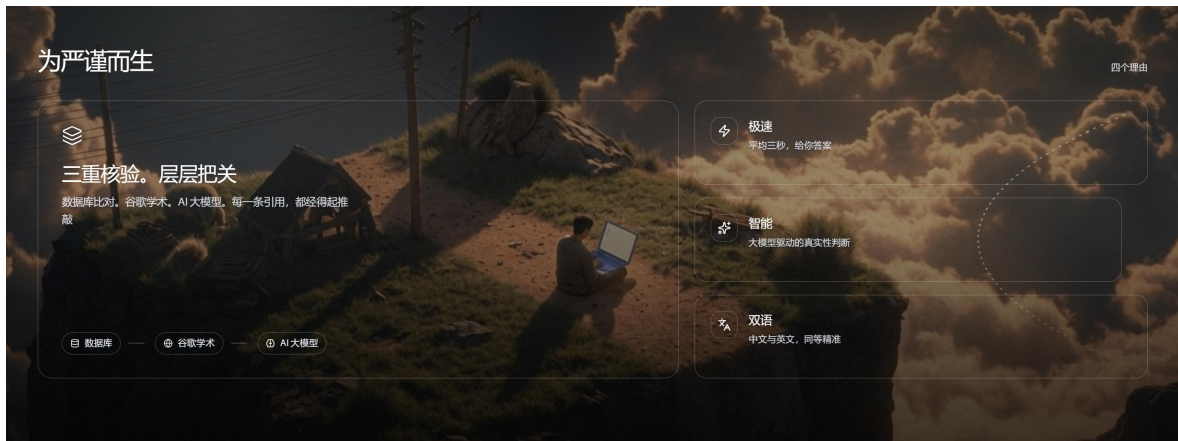


图 2.7: 系统首页 (续)



图 2.8: 系统首页 (续)

2.3.2 用户认证与访问管理

为保障用户检测记录和任务数据的连续性，平台设计了用户认证与访问管理功能。用户可在注册页面创建账户，并从登录页面进入系统。系统在后端使用本地数据库保存用户信息，并对密码进行哈希处理，避免明文存储带来的安全风险。

登录成功后，前端会保存用户登录状态，用户刷新页面或重新打开浏览器后仍可保持会话状态。对于简单检索、批量检索、检测结果和历史记录等核心功能页面，系统设置了访问控制，未登录用户会被自动引导至登录页面。该设计既提升了平台的安全性，也为后续检测历史管理和个性化服务提供了基础。




图 2.9：登录界面

2.3.3 文献检索与检测结果展示

平台支持单条文献真实性检索，满足用户快速核验某一篇论文或某一条参考文献的需求。用户可在“简单检索”页面选择中文文献或英文文献模式，并在输入框中粘贴或输入待检测论文标题。提交后，系统会根据文献语言类型调用对应检索链路，对输入标题进行标准化处理、候选文献召回和相似度匹配。

英文文献主要依托本地 DBLP 文献数据库进行候选召回，并结合模糊匹配算法计算标题相似度；中文文献通过百度学术获取候选结果并完成匹配。用户可根据系统返回的匹配标题、相似度分数和核验状态判断引用是否真实存在。该功能操作简单、反馈迅速，适用于写作过程中对可疑引用的快速验证。




图 2.10：单条文献检索

此外，为解决论文参考文献数量较多、人工逐条核查效率低的问题，平台提供批量文献检测功能。用户可在批量检索页面一次性输入多条论文标题，每行对应一条待检测文献。系统接收标题列表后，会自动构建检测任务，并发执行真实性核验。平台还支持 CSV 文件导入，系统自动识别标题列并将其提取为待检测列表。该功能适用于用户已经整理好参考文献，或需要对大量结构化文献进行集中核验的场景。




图 2.11：批量文献检索

系统的批量检测还支持 PDF 智能解析，主要面向用户拥有论文 PDF 但不希望手

动复制参考文献的场景。用户可在批量检索页面选择“上传 PDF”功能，将论文上传至系统。系统接收并解析文件后，会自动定位到参考文献区域，并对参考文献条目进行切分和清洗；随后通过大语言模型辅助提取可用于检索的标题字段，所得结果自动进入批量检测链路，实现从 PDF 上传到引用真实性核验的自动化处理。

在检测过程中，系统会实时统计任务总数、已处理数量、匹配成功数量和未匹配数量，并在前端页面展示处理进度。该功能能够显著减少用户重复输入和逐条检索的工作量，提高大规模引用核验效率。




图 2.12: PDF 文档上传及检索

展示检测结果时，系统不仅提供“真实引用”、“疑似异常引用”、“无法验证引用”和“检索异常”等状态标签，还会展示输入标题、匹配的候选标题、相似度分数、数据来源、检测时间等关键信息。




图 2.13：单条文献检索结果

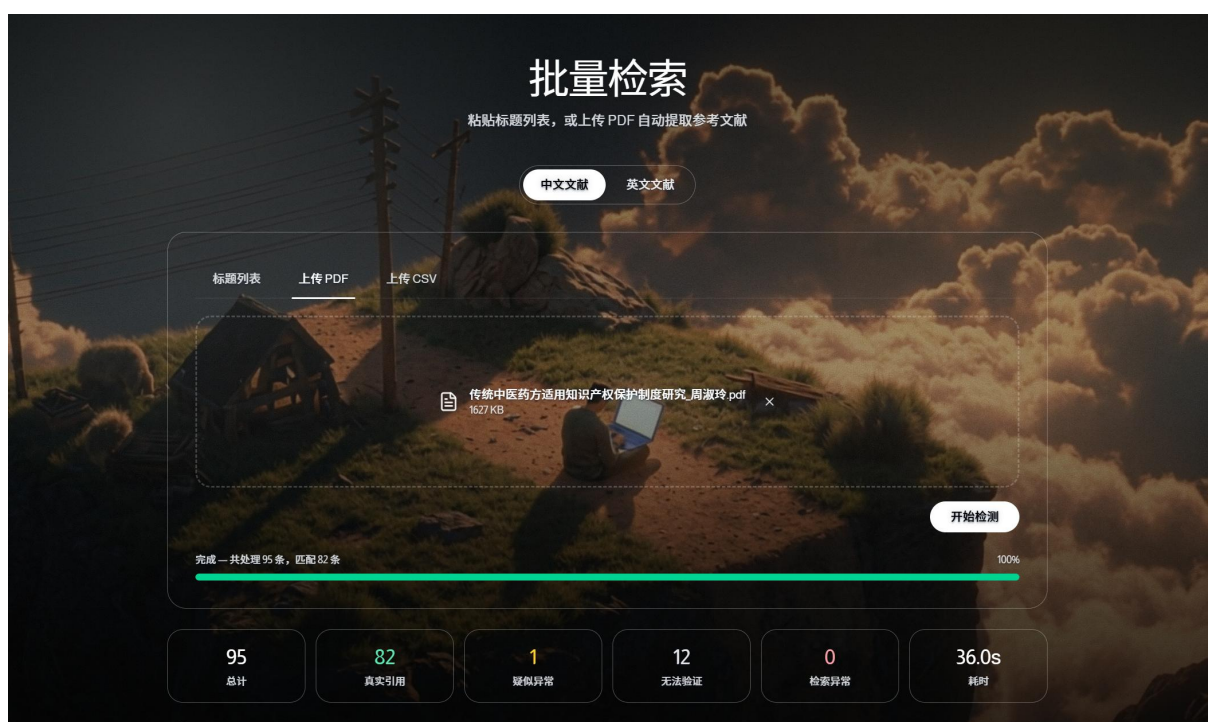


图 2.14：批量文献检索结果

2.3.4 历史记录管理

为便于用户后续查看、复核和归档检测结果，平台提供历史记录管理功能。系统

会记录每次检测任务的日期、输入数量、匹配数量、未匹配数量和耗时等信息，并在历史记录中以列表形式展示。用户可通过点击某条任务查看详细检测结果。

该功能适用于论文多次修改、导师审核、团队协作和科研管理等场景。用户无需重复上传相同文件或重新输入标题，即可回溯之前的检测结果。同时，系统支持将检测结果导出为 CSV 文件，便于用户进行统计分析。



图 2.15：历史记录

2.3.5 多语言及中英文文献适配

平台提供多语言界面和中英文文献检测能力，能够适配不同语言背景用户的使用需求。前端导航栏设置语言切换入口，支持中文、英文以及其他扩展语言界面，提升系统在跨语言学术场景中的可用性。

在文献核验层面，系统根据用户选择或标题内容区分中文文献与英文文献，并调用不同的数据源和检索策略。通过中英文分流和统一结果展示，平台能够处理中文、英文以及中英文混合参考文献列表，提高了适配能力。




图 2.16: 阿拉伯语首页界面




图 2.17: 俄语首页界面

2.3.6 平台扩展服务

为提升平台的信息完整性和后续扩展能力，系统提供“更多”页面，用于承载平台说明、研究成果、常见问题、更新日志、API 文档和用户反馈等扩展服务。页面通过卡片式布局集中展示系统背景、团队成果和使用支持信息，帮助用户进一步了解平台的研究基础与应用价值。

其中，“关于我们”用于介绍平台建设目标和设计理念；“团队成果”用于展示与 CiteVerifier 相关的研究成果和学术产出；“常见问题”用于解答用户在使用过程中典型疑问；“更新日志”用于记录平台功能迭代情况；“API 文档”面向开发者提供后续接口接入说明；“用户反馈”则为系统持续优化提供信息收集入口。该功能使 CiteVerifier 不仅具备引用检测能力，也具备产品化展示和开放服务的基础。

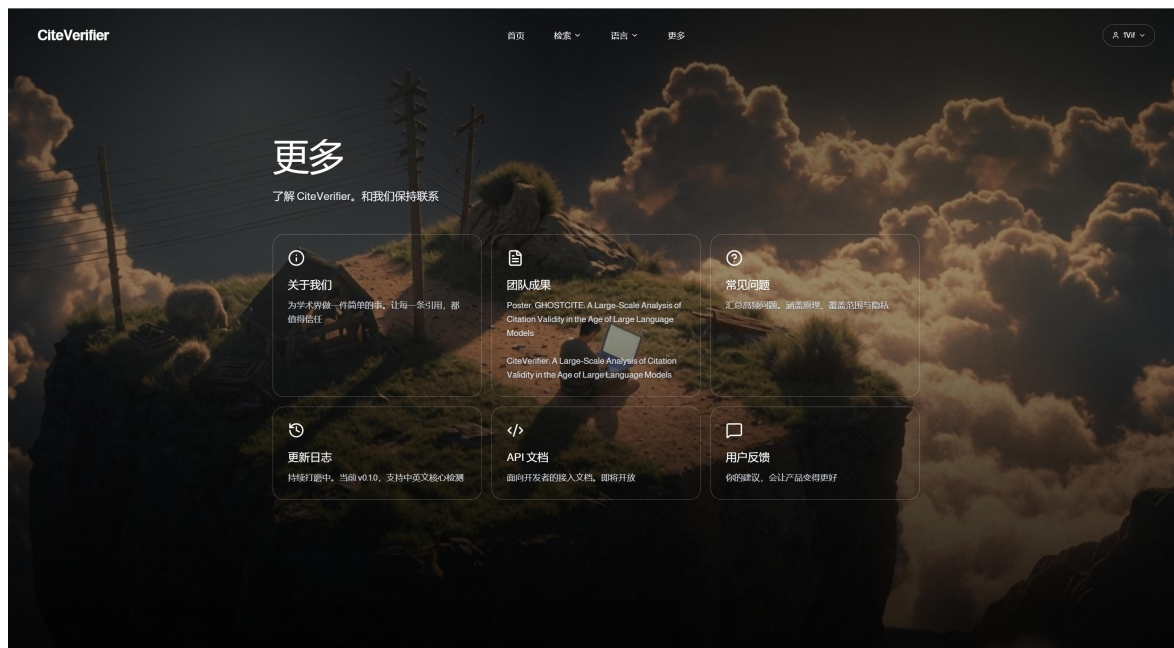


图 2.18: 更多信息

第三章 作品测试与分析

3.1 功能性测试

为全面验证 CiteVerifier 平台在真实应用场景下的可用性、稳定性与安全性，本章节从功能完整性、系统性能以及兼容性等多个维度开展测试。

3.2.1 测试目标

1. 前端功能测试

前端测试采用黑盒测试方法，分别设计正常输入、空值输入、超长文本输入以及包含非法特殊字符输入等多种测试场景，对比系统实际反馈结果与预期设计结果，验证页面交互逻辑、状态切换及异常处理机制是否符合设计要求。

2. 后端接口与业务逻辑测试

测试过程中分别构造合法请求、缺失参数请求、异常参数请求以及高频并发请求等多种场景，对接口返回状态码、响应报文格式、数据库读写结果以及异步任务调度逻辑进行校验，确保后端业务流程能够正确执行，并保证前后端数据交互稳定可靠。

3. 性能测试

通过选取不同规模的引用集合（10 条、32 条、50 条及 100 条）作为测试对象，统计各规模任务下的总检测耗时、CPU 占用率及内存使用情况，对系统的并发解析能力进行验证。

4. 兼容性测试

兼容性测试覆盖 Chrome、Edge 等主流浏览器，windows、linux 等主流操作系统，并对多语言界面切换进行验证；

3.2.2 测试环境搭建

DBLP 数据库配置：在 dblp 官网下载 dblp.xml 和 dblp.dtd，解压后放在项目根目录，使用 build_dblp_sqlite 脚本进行建库，可以通过以下参数完成数据库的自定义创

建:

```
1. dblp_xml="dblp.xml"
2. db_path="./dblp.sqlite"
3. batch_size=50000 //单批次大小
4. use_fts=True //使用 FTSS 索引优化查询速度
```

依赖包安装: 我们推荐使用 Conda 来管理 Python 环境，避免依赖冲突。

```
1. //创建虚拟环境
2. conda create -n CiteVerifier python=3.10
3. //启动环境:
4. conda activate CiteVerifier
5. //根目录一键安装所有依赖
6. .\start.bat
```

平台启动: 默认情况下，平台将监听本机的 **8080** 端口。打开浏览器，访问 **http://127.0.0.1:8080/**，若能看到如下首页界面，即部署成功。



图 3.1: 系统启动界面

3.2.3 测试结果与分析

测试	测试用例数	通过数	通过率
前端交互	35	35	100%
后端接口	17	17	100%
PDF 解析	8	8	100%
兼容性	9	9	100%

合计	69	69	100%
----	----	----	------

表 3.2: 功能性测试结果

本次功能性测试围绕**前端交互**、**后端接口**、**PDF 解析与兼容性**四大测试项目共设计 69 项测试用例，覆盖系统核心业务流程、异常处理机制、并发性能与跨环境适配等关键维度，所有测试用例全部通过，整体通过率达 100%，系统功能完整性与运行稳定性均达到设计预期。

3.2 有效性测试

有效性测试旨在验证 CiteVerifier 在真实科研环境下的识别能力。

3.2.1 测试目标

本次测试重点验证以下两个方面：

- **算法检测精度：** 测试系统对真实引用、存在轻微错误的有效引用以及 AI 生成的虚假引用三类样本的区分能力，评估两阶段检索与模糊匹配算法的综合识别效果。
- **现实场景应用价值：** 对主流大语言模型生成引用及顶级学术会议论文中的引用进行批量核验，评估 AI 幻觉引用的现实危害。

3.2.2 测试数据集

为保证测试结果的真实性与代表性，本系统构建了覆盖真实学术场景、模型生成场景及边界异常场景的综合测试数据集，并依托团队前期研究成果建立统一的测试基准。

- **基准文献库。**系统以 DBLP 学术文献数据为基础，通过解析、清洗与结构化处理，建立本地 SQLite 文献数据库，覆盖计算机科学领域数百万条文献记录。
- **真实引用样本。**从团队构建的 2020-2025 年国际顶级 AI/ML 与网络安全会议论文数据集中抽取真实参考文献样本，包括 NeurIPS、NDSS 等多个重要会议，累计覆盖约 220 万条真实引用记录。
- **AI 幻觉引用样本。**收集 GPT、Claude 等 13 款主流 LLM 生成的大量参考文献数据，覆盖 40 个计算机科学研究方向。

3.2.3 测试结果与分析

1. 主流大语言模型幻觉引用测试

团队分别要求 13 款主流大语言模型生成 JSON 格式的参考文献，对生成数据进行自动化核验并统计各模型的幻觉引用率。

模型名称	JSON 格式 (%)	生成数据量	幻觉率 (%)	95%CI
DeepSeek	97.67	27,973	14.23	1.55
GLM-4.5	97.22	27,835	21.25	1.94
Claude 4	100.00	28,800	21.84	1.93
Qwen-3	99.38	28,546	23.52	1.99
Kimi	89.09	24,955	41.86	2.44
Llama 4	97.33	27,925	45.84	2.36
GPT-5	97.90	28,366	50.92	2.36
Gemini	95.80	27,102	59.47	2.34
ERNIE	95.06	27,332	71.90	2.15
Seed	48.75	11,090	78.64	2.74
Grok 4	99.03	28,627	79.98	1.88
Phi-4	93.35	27,164	87.47	1.60
Hunyuan	62.90	16,094	94.93	1.29

表 3.4：13 种主流大语言模型幻觉引用率统计表

测试结果表明，13 款模型均受到幻觉问题影响，但生成虚假引用的比例存在较大差异。部分模型生成的参考文献中超过一半无法在真实学术数据库中检索到，而个别模型的幻觉引用比例甚至接近 95%。

2. 顶级学术会议中的虚假文献检测

实验检测了来自多个国际顶级会议的 56,381 篇论文，累计分析超过 220 万条参考文献记录。

会议名称	元数据错误引用数	无法追踪来源引用数	虚假引用数	含有错误引用的论文数	错误率
NeurIPS	59	332	391	308	1.51%
ICML	22	103	125	104	0.93%
AAAI	21	85	106	86	0.62%
IJCAI	11	42	53	51	0.96%
NDSS	4	19	23	18	2.56%
CCS	11	9	20	20	1.14%
USENIX	6	6	12	11	0.57%
S&P	1	7	8	6	0.56%

表 3.5: 2020-2025 年之间计算机学术顶会虚假引用情况

统计结果显示，在全部检测论文中，约有 1.07% 的论文包含至少一条无法在权威学术数据库中检索到的无效引用。进一步分析发现，顶级会议论文中的无效引用数量呈现持续增长趋势，其中 2025 年检测到的无效引用规模较上一年度增长约 80.9%，增长速度显著加快。这一结果表明，AI 幻觉引用已经突破模型实验环境，开始进入真实学术传播链条。

3.3 作品学术成果

本作品已形成以下学术成果：

成果一：海报 Poster: GHOSTCITE: A Large-Scale Analysis of Citation Validity in the Age of Large Language Models，已被第 47 届 **IEEE 安全与隐私研讨会**接收为 Poster。

Poster: GhostCite: A Large-Scale Analysis of Citation Validity in the Age of Large Language Models

The Framework of CiteVerifier [1] and Experiment Design

- Parsing Stage.** Extract metadata from PDF citation strings with GROBID. If parsing fails, Qwen3-Flash re-extracts key fields such as the title.
- Verification Stage.** Query the local cache, DBLP, and Google Scholar in sequence. If all fail, the system re-parses the citation and retries.
- Classification Stage.** Compare the input title with the best retrieved title using normalized Levenshtein similarity. Citations below 0.9 are labeled as ghost citations.
- Reliability Check.** We manually reviewed 400 "valid" citations (95% confidence, 5% margin) and found no additional invalid ones.




Figure 1. The framework of CiteVerifier and experimental pipeline.

We deploy CiteVerifier in three complementary experiments to investigate ghost citations:

- LLM Benchmark.** Evaluate 13 LLMs across 40 CS domains (about 375K generated citations) to quantify hallucination rates under varied prompting conditions.
- Archival Analysis.** Analyze 56,381 papers from top AI and Security venues (2020-2025), combining automated screening with manual verification to measure real-world prevalence.
- User Study.** Survey active researchers on citation practices and verification behaviors to understand human factors enabling ghost citations to persist.

Measuring the Unreliability: LLM Benchmark

- High Hallucination Rates.** All 13 LLMs show substantial citation hallucination, from 14.23% to 94.93%.
- Domain Sensitivity.** Performance varies widely across domains. Some models do well in one area but fail in others.
- Poor Validation Performance.** LLMs are unreliable at verifying citation validity, achieving only 38% accuracy.

Table 1. LLM performance on citation generation.

Model	Valid JSON (%)	Citations	Halluc. (%)	95% CI
DeepSeek	97.67	27,973	14.23	±1.65
GLM-4.5	97.22	27,835	21.25	±1.94
Claude-4	100.00	28,820	21.94	±1.93
Qwen-3	99.38	28,546	23.52	±1.99
Kimi	89.09	24,955	41.86	±2.44
Llama-4	97.33	27,925	45.84	±2.36
GPT-5	97.90	28,346	50.92	±2.36
Gemini	95.80	27,102	59.47	±2.34
ERNIE	95.06	27,332	71.90	±2.15
Seed	48.75	11,090	78.64	±2.74
Grok-4	99.03	28,627	79.98	±1.88
Phi-4	93.35	27,164	87.47	±1.60
Hunyuan	62.90	16,094	94.93	±1.29

Halluc.: Hallucination rate, the percentage of citations verified as invalid.
95% CI: Confidence interval margin (a) for the hallucination rate.

Table 2. Citation validity judgment accuracy.

Model	Valid Recall	Invalid Precision	Accuracy
ERNIE	6/50 (12%)	50/50 (100%)	56/100 (56%)
Hunyuan	19/50 (38%)	29/50 (58%)	48/100 (48%)
Seed	31/50 (62%)	16/50 (32%)	47/100 (47%)
Phi-4	12/50 (24%)	29/50 (58%)	41/100 (41%)
Kimi-42	14/50 (28%)	26/50 (52%)	40/100 (40%)
GPT-5	8/50 (16%)	28/50 (56%)	36/100 (36%)
Llama-4	19/50 (38%)	16/50 (32%)	35/100 (35%)
DeepSeek	16/50 (32%)	19/50 (38%)	35/100 (35%)
Qwen-3	13/50 (26%)	21/50 (42%)	34/100 (34%)
Gemini	20/50 (40%)	12/50 (24%)	32/100 (32%)
Grok-4	14/50 (28%)	18/50 (36%)	32/100 (32%)
GLM-4.5	19/50 (38%)	14/50 (28%)	33/100 (33%)
Claude-4	12/50 (24%)	15/50 (30%)	27/100 (27%)
Average	15/50 (30%)	23/50 (46%)	38/100 (38%)

LLMs evaluated on manually verified ground truth from archival analysis (50 valid + 50 invalid entries).




Figure 2. Model-domain hallucination rate heatmap.

Hunting for Ghosts: Archival Analysis

- Ghost citations have entered top venues.** Across 2.2M citations from 56,381 papers (2020-2025) across eight leading AI and security venues, we found 604 papers with invalid references after manual review of 2,530 CiteVerifier flagged citations.
- Two failure types matter.** We found 603 ghost citations, which point to unverifiable works, and 135 metadata errors, which point to real works with wrong citation fields. At the paper level, 486 papers contain ghost citations and 133 contain metadata errors.
- The share of papers with invalid citations rose in 2025.** From 2020 to 2024, the proportion stayed between 0.76% and 0.98%, then increased to 1.61% in 2025, with up to nine ghost citations in a single manuscript.
- Errors can spread across the community.** By tracing citation chains, we found that a single metadata error from OpenReview citation export was replicated in at least 16 independent conference papers.

Table 3. Invalid citations by conference.

Conf.	Error	Ghost	Invalid Papers	Rate	Conf.	Error	Ghost	Invalid Papers	Rate
NeurIPS	59	332	391	308 1.51%	NDSS	4	19	23	18 2.56%
ICML	22	103	125	104 0.93%	CCS	11	9	20	20 1.14%
AAAI	21	85	106	86 0.62%	USENIX	6	6	12	11 0.57%
UAI	11	42	53	51 0.96%	S&P	1	7	8	6 0.56%
Total	135	603	738	604 1.07%					

Invalid: Error + Ghost citations.
Rate: Percentage of papers with invalid citations.
Conf.: Conference acronym.




Figure 3. Time trends of papers with invalid citations.

Analyzing Human Factors: Survey Findings

- We collected 94 valid responses from researchers across AI and security. Among them, 82 had published papers and 32 had reviewer experience.
- Widespread AI Adoption.** 87.2% of respondents use AI tools primarily for text polishing and integrate AI-generated content, including citations, into their writing workflows.
- Verification Gap.** Despite reporting that they verify references, 41.5% of respondents copy and paste BibTeX without checking, and 76.7% of reviewers do not thoroughly check reference lists.
- Ineffective Peer Review.** 74.5% view peer review as ineffective at catching citation errors, and 80.0% of reviewers rarely suspect fake citations.
- High Support for Automation.** 70.2% strongly support deploying automated DOI and reference checks in submission systems.

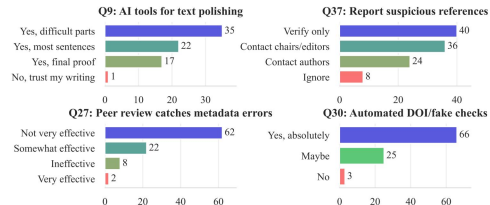


Figure 4. Key questions on AI adoption, reporting behavior, peer review efficacy, and support for automated checks.

References

- [1] Ziyao Xu, Yuxi Qiu, Lu Sun, Fasheng Mao, Fubin Wu, Xinyi Wang, Xiang Li, Haozhe Lu, Zhengze Zhang, Yuxin Hu, et al. GhostCite: A large-scale analysis of citation validity in the age of large language models. *arXiv preprint arXiv:2602.06718*, 2026.

图 3.6: 已被接收海报

成果二：论文 GhostCite: A Large-Scale Analysis of Citation Validity in the Age of Large Language Models 已发布于 arXiv 预印本平台 (arXiv:2602.06718, 2026)，并投稿至 AAAI 2027，目前处于审稿阶段。

GHOSTCITE: A Large-Scale Analysis of Citation Validity in the Age of Large Language Models

Anonymous Author(s)

Abstract—Citations provide the basis for trusting scientific claims; when they are invalid or fabricated, this trust collapses. With the advent of Large Language Models (LLMs), this risk has intensified: LLMs are increasingly used for academic writing, but their tendency to fabricate citations (“ghost citations”) poses a systemic threat to citation validity. To quantify this threat, we develop CITEVERIFIER, an open-source framework for large-scale citation verification, and conduct a comprehensive study of citation validity in the LLM era through three complementary experiments. First, we benchmark 13 LLMs on citation generation task in various research domains, finding that all models hallucinate citations at rate from 14.23% to 94.93%. Second, we analyze 2.2 million citations from 56,381 papers at AI/ML and Security venues (2020–2025), finding that 1.07% of papers contain invalid citations, with an 80.9% increase in 2025. Third, we survey 97 researchers, finding that 87.2% use AI-powered tools in their workflows, 76.7% of reviewers do not thoroughly check references, and 74.5% view peer review as ineffective at catching citation errors. Based on these findings, we argue that ghost citations represent a systemic threat to academic integrity, and call for coordinated efforts from community to address this challenge.

I. INTRODUCTION

Citations serve as a trust mechanism that justifies scientific claims [1]: readers assume that cited work exists and supports the claims being made, and rarely verify that it does [2]. However, when a citation is invalid, this trust mechanism collapses. A fabricated citation can misattribute foundational ideas, introduce phantom prior work, misdirect subsequent research investment, or undermine the evidentiary chain of a claimed contribution, threatening the integrity of the entire research community. The advent of AI-assisted writing has introduced a novel threat to this academic trust infrastructure. Researchers increasingly leverage LLMs to synthesize literature reviews, curate related work, or compile reference lists [3]. When prompted for citations, these systems do not look up references. Instead, leveraging their inherent generative nature, they *synthesize* references by combining statistically correlated tokens (real author names, plausible-sounding titles, and prestigious venue names) into citations that appear authentic despite being entirely fabricated [4]. This phenomenon commonly described as “ghost citations” [5], [6], representing a new category of academic misconduct:

high-fidelity fabrications that exploit the format-compliance of bibliographic conventions to evade detection. The emergence of ghost citations has caught the attention of conferences and governing bodies in academia. For instance, ICLR 2026 chairs issued guidelines warning against AI-generated content, including fabricated citations [7], and major publishers such as IEEE have established policies requiring disclosure of AI usage in manuscripts [8]. Recent reports also document hallucinated citations in conference submissions and accepted papers, as well as in domain-specific analyses [9]–[11]. However, despite growing awareness, we still lack systematic answers to three fundamental questions:

- *Q1: How frequently do LLMs hallucinate citations across research domains?*
- *Q2: To what extent have invalid citations entered published academic literature?*
- *Q3: Why do authors and reviewers fail to detect them?*

Research Gap Prior work and policy discussions highlight the risks of ghost citations [7], [12], [13], but to answer the above questions, three practical gaps persist. First, the scale of the problem is unknown: we have no empirical measurement of how often LLMs fabricate and how many invalid citations have entered the published record. Second, there is no scalable way to detect citations validity, because they often deviate from standard formats and need to be verified against multiple bibliographic sources. Third, we lack a clear understanding of how invalid citations go through researcher’s draft and peer review process and end up in the published record without being checked. These gaps motivate our work, which develops a technical framework for large-scale citation verification and applies it to systematically analyze the prevalence of ghost citations in LLM outputs and the published record, as well as the human behaviors that allow them to persist.

Our Study. In this paper, we develop CITEVERIFIER, an open-source framework for large-scale citation verification, and conduct three complementary experiments that answer the above research questions.

Experiment 1: LLM Benchmark We evaluate 13 state-of-the-art LLMs across 40 computer science research domains aligned with arXiv CS subject classes [14], finding that all models hallucinate citations at rates ranging from 14.23% to 94.93%, with substantial variation across domains (Section V).

Experiment 2: Archival Analysis. We collected [15] 56,381 papers from eight AI/ML and Security venues spanning 2020 to 2025. After employing CITEVERIFIER to analyze 2.2 million citations of these papers, our system flagged 2,530 citations for unmatched metadata. We then manually verified

图 3.7: 在投论文

第四章 创新性说明

多源学术数据支撑的引用真实性核验方法。现有文献核验工具大多依赖 DOI 等标识符，面对 DOI 缺失、字段不完整等问题时核验受限。同时，单一在线接口由于访问限制，难以满足稳定的批量化引用核验需求。

针对上述问题，系统设计了多源数据支撑的引用真实性核验方法。系统以参考文献标题作为核心匹配依据，结合本地文献数据库和在线学术检索源，通过候选召回与相似度计算完成验证。英文文献主要依托本地 DBLP 数据库实现模糊匹配和快速检索，中文文献通过百度学术获取候选结果，并基于标题相似度进行判断。

该方法的创新性在于，将引用核验从“标识符精确查询”扩展为“多源数据支撑下的标题级近似匹配”，兼顾检索的稳定性、效率和覆盖范围，从而适应中英文混合、无 DOI、标题存在轻微差异等真实场景。这一举措提升了系统对 AI 幻觉引用的识别能力，也为更多学术数据源的接入提供了基础。

面向非结构化参考文献的大语言模型辅助解析方法。针对非结构化参考文献编号排版风格不同、字段粘连、中英文混排等问题，本系统引入大语言模型辅助解析。系统首先解析 PDF 文档并自动定位参考文献区域，随后结合编号识别、条目切分、格式清洗和大语言模型语义解析，将非结构化文本转换为可检索的结构化数据。对于无编号、格式不规范的参考文献，大语言模型能够辅助识别标题、作者、年份等关键字段，为核验提供稳定输入。

该方法的创新性在于，将规则解析的确定性与大语言模型的语义理解能力相结合，提升了系统对复杂 PDF 文档和多格式参考文献的适应能力。用户只需上传 PDF 文件，系统即可自动完成提取与核验，显著降低使用门槛，提高检测的自动化程度。

面向 AI 幻觉引用的安全应用场景设计。随着大语言模型在学术写作中的广泛应用，“幻觉引用”现象逐渐成为影响学术信息可信度的重要问题，也是 AI 内容安全治理亟需应对的现实挑战。

本系统从安全视角出发，构建了从参考文献提取、结构化解析、候选文献检索到真实性验证的完整检测流程，能够针对标题虚构、来源无法追溯等问题进行自动化筛查，帮助用户提前发现风险。

该应用设计的创新性在于，将传统信息安全中对数据真实性、完整性的关注扩展到学术引用场景，面向生成式人工智能带来的内容可信风险提供了可部署、可扩展的技术工具。系统可应用于单篇论文检查、期刊论文审核和 AI 生成内容治理等场景，对于提升学术信息可信度、促进生成式人工智能安全应用具有一定的研究价值和实践意义。

第五章 总结

本项目围绕 AI 幻觉引用问题，完成了 CiteVerifier 智能核验系统的设计、开发与测试，构建了一套面向参考文献真实性核验的自动化检测方案，实现了从文献提取、检索到真实性判定的完整流程。

针对传统核验依赖 DOI、人工核查效率低等问题，系统采用多数据源联合核验策略，实现了中英文文献的统一检测；同时结合大语言模型辅助解析，支持复杂 PDF 中参考文献的自动提取，显著提升了核验效率和适用性。测试结果表明，系统对真实引用、元数据错误的引用以及 AI 生成的幻觉引用均具有较好的识别能力，并能够在复杂 PDF 文档及多语言场景下保持良好的鲁棒性。此外，系统还通过密码哈希存储、身份认证等措施，保障了数据安全与服务可靠性。

从信息安全角度来看，CiteVerifier 将传统信息安全对数据真实性的关注延伸至 AI 时代的知识可信验证领域，通过自动化引用核验机制实现对学术内容真实性的主动检测，符合当前人工智能安全治理的发展方向。

未来，CiteVerifier 可进一步融合知网等国内公开学术数据库，同时结合知识图谱技术实现引用关系推理与可信度评估，构建更加智能化的学术内容安全分析平台。总体而言，CiteVerifier 不仅是一套智能检测系统，更是服务于科研诚信建设与 AI 安全治理的创新实践，为构建可信科研生态提供了有益探索。

参考文献

- [1] Ji Z, Lee N, Frieske R, et al. Survey of hallucination in natural language generation[J]. ACM computing surveys, 2023, 55(12): 1-38.
- [2] Ansari S. Compound Deception in Elite Peer Review: A Failure Mode Taxonomy of 100 Fabricated Citations at NeurIPS 2025[J]. arXiv preprint arXiv:2602.05930, 2026.
- [3] Mata v. Avianca, Inc., 678 F. Supp. 3d 443 (S.D.N.Y. 2023).
- [4] Bender E M, Gebru T, McMillan-Major A, et al. On the dangers of stochastic parrots: Can language models be too big?[C]//Proceedings of the 2021 ACM conference on fairness, accountability, and transparency. 2021: 610-623.
- [5] Zuccon G, Koopman B, Shaik R. Chatgpt hallucinates when attributing answers[C]//Proceedings of the Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region. 2023: 46-51.
- [6] Naser M Z. How LLMs Cite and Why It Matters: A Cross-Model Audit of Reference Fabrication in AI-Assisted Academic Writing and Methods to Detect Phantom Citations[J]. arXiv preprint arXiv:2603.03299, 2026.
- [7] Crossref. REST API - Crossref.<https://www.crossref.org/documentation/retrieve-meta-data/rest-api/>
- [8] DBLP. dblp: computer science bibliography.<https://dblp.org/>
- [9] Hallucinator. hallucinator: Hallucinated Reference Detector.<https://github.com/gianlu-casb/hallucinator/>.
- [10] Xu Z, Qiu Y, Sun L, et al. GhostCite: A large-scale analysis of citation validity in the age of large language models[J]. arXiv preprint arXiv:2602.06718, 2026.
- [11] Levenshtein V I. Binary codes capable of correcting deletions, insertions, and reversals[C]//Soviet physics doklady. 1966, 10(8): 707-710.